

INSPER · AULA 07 · CIBERSEGURANÇA · CIÊNCIA DA COMPUTAÇÃO

Como detectar fraudes quando os casos positivos são *raríssimos*?

Dados desbalanceados: conceitos e a atividade de estratégia

PROFESSOR

João Luisi

TEMA

Deteção de fraude · classes raras

```
~$ python treinar.py creditcard.csv
[*] 284.807 transações · 492 fraudes (0,172%)
    acurácia: 0.9983
    fraudes detectadas: 98
# acurácia alta, modelo inútil

LogisticRegression(
class_weight="balanced")
```



ONDE ESTAMOS NA ESCADA

Do sinal à *avaliação séria*



No Roteiro 2 o CICIDS2017 tinha ataques em abundância. Fraude de cartão é outro mundo: 1 caso positivo para cada 578 negativos. As técnicas de hoje são pré-requisito do Roteiro 3.

INTRODUÇÃO

Por que fraude é um problema de ML *diferente*

DESBALANCEAMENTO

Positivos raríssimos

Fração de 1%. O modelo pode **ignorar a classe minoritária** e ainda parecer excelente.

TEMA DE HOJE

CUSTO

Custo assimétrico

Uma fraude perdida e um alarme falso custam coisas diferentes, para pessoas diferentes. Sem esses custos não existe "melhor modelo".

TEMA DA AULA 10

ADVERSARIAL

O alvo se move

O fraudador aprende com o que é bloqueado e muda. A distribuição das fraudes se move; a dos gatos em fotos, não.

TEMA DA AULA 20

RÓTULO

Atrasado e incompleto

Uma fraude só vira rótulo quando alguém reclama, semanas depois. Os "legítimos" contêm **fraudes escondidas**.

SEMPRE PRESENTE

O DATASET · CARTÕES DE CRÉDITO · SETEMBRO DE 2013

Dados reais de fraude, *anonimizados por PCA*

284.807

transações em dois dias

492

fraudes

0,172%

taxa de fraude (578 : 1)

- ◆ **Time** e **Amount** são as únicas colunas originais.
- ◆ **V1** a **V28** são componentes de PCA: os atributos originais (lojista, local, tipo de cartão) **não foram divulgados**.
- ◆ A PCA é o que permitiu publicar dados reais de fraude. O preço: **nenhuma feature é interpretável**.
- ◆ ULB Machine Learning Group, publicado no Kaggle e no OpenML.

O PARADOXO DA ACURÁCIA

Um modelo que responde *"legítima" para tudo*

99,83% de acurácia

0 fraudes detectadas de 98

Acurácia mede "**quantas vezes acertei**". Quando 99,83% dos casos são de uma classe só, acertar é repetir a maioria.

A REGRA DA AULA

A partir de agora todo resultado vem com **duas contagens**: quantas fraudes o modelo pegou e quantos alarmes falsos gerou.



AS DUAS CONTAGENS QUE IMPORTAM


A matriz de *confusão*

	MODELO DIZ: FRAUDE	MODELO DIZ: LEGÍTIMA
É FRAUDE	Fraude detectada VERDADEIRO POSITIVO ≤ 98	Fraude perdida FALSO NEGATIVO
É LEGÍTIMA	Alarme falso FALSO POSITIVO	Legítima aprovada VERDADEIRO NEGATIVO 56.864

- ◆ A acurácia soma as **diagonais** e divide pelo total. O canto inferior direito tem 56.864 casos; o superior esquerdo, no máximo 98.
- ◆ O que o time de fraude quer saber: **quantas das 98 pegamos**, e quantos clientes legítimos incomodamos.

*Cada técnica de hoje **move casos entre estes quadrantes**. Nenhuma cria informação nova.*

Por que a fronteira *se acomoda*



O RESULTADO

62 / 98

fraudes detectadas

13

alarmes falsos

36 (37%)

fraudes perdidas

O MECANISMO

**O otimizador
vai para onde
dói menos**


O otimizador minimiza o **erro total**. Errar uma fraude custa o mesmo que errar uma legítima, e há **578 legítimas para cada fraude**.

A fronteira se acomoda do lado que dói menos: **o lado da maioria**.

TÉCNICA 1 · UNDERSAMPLING

Jogar fora a *maioria*

Descartar transações legítimas do treino, ao acaso, até que as classes fiquem **1:1**. O conjunto de teste não é tocado.



O QUE SE ESPERA

Treino instantâneo. A fronteira deixa de ser puxada por **578 pontos de um lado** para cada um do outro.

O PREÇO

Perde-se quase todo o conhecimento sobre o que é "**normal**". O que foge um pouco do padrão dos poucos legítimos restantes vira suspeito.

*Descartar dados é barato e rápido, mas você está **apagando a definição de normal** para enxergar melhor o raro.*

TÉCNICAS 2 E 3 · OVERSAMPLING E SMOTE


Duplicar ou *inventar* fraudes

OVERSAMPLING ALEATÓRIO

Copia fraudes existentes até 1:1. Nenhuma informação nova; o modelo vê as mesmas **394 fraudes** centenas de vezes.

SMOTE · CHAWLA ET AL., 2002

Para cada fraude, escolhe um dos 5 vizinhos mais próximos e **cria um ponto no segmento entre os dois**.



PONTOS LARANJA: FRAUDES SINTÉTICAS INTERPOLADAS ENTRE FRAUDES REAIS

- ◆ Onde fraudes reais estão isoladas, o SMOTE **atravessa regiões vazias** e ensina fraude onde nunca houve.
- ◆ Vizinhos por distância euclidiana: as features precisam estar na mesma escala. Supõe features contínuas.

TÉCNICA 4 E A ALAVANCA · SEM MEXER NOS DADOS

Pesos e *limiar*

PESOS NA FUNÇÃO DE CUSTO

`class_weight="balanced"`: cada fraude passa a pesar **578 vezes mais** que uma legítima no erro que o modelo minimiza. Sem cópias, sem sintéticos, sem 454 mil linhas na memória.



LIMIAR DE DECISÃO

O modelo devolve uma **probabilidade**. Cortar em **0,5** é uma convenção. Cortar em **0,1** detecta mais e alarma mais, **sem retreinar nada**.

A PERGUNTA QUE A DEMONSTRAÇÃO VAI RESPONDER

Quatro técnicas (undersampling, oversampling, SMOTE, pesos) e uma alavanca (limiar). **Elas criam informação nova ou apenas movem a fronteira?** E o que acontece com os alarmes falsos em cada caso?

A FRAUDE NO MUNDO REAL

Do algoritmo ao *crime organizado*

A transação fraudulenta é só o começo. Atrás dela há dados vazados, contas de terceiros e dinheiro que precisa sumir. Detectar fraude é um elo de uma investigação maior.

O tamanho do problema, *em números reais*

47,9%

o golpe mais comum de 2024 foi o uso indevido de cartão de crédito

R\$ 2,5 bi

em perdas com fraude bancária no Brasil (2022); só ~5% recuperado

2,1 mi

cartões vazados de uma vez no fórum Biden Cash; ~19 mil brasileiros

- ◆ **Abecs:** as fraudes com cartões caíram 18% em 2024. Nos pagamentos presenciais, são cerca de **4 fraudes a cada 100 mil transações** — a defesa evoluiu.
- ◆ **Febraban:** clonagem ou troca de cartão respondeu por **44% dos crimes** registrados no sistema financeiro em 2024.
- ◆ **Dez/2024, Rio de Janeiro:** a PF prende o "professor do golpe digital"; o grupo clonou **mais de 10 mil cartões** em um trimestre e ensinava outros a fraudar.

FONTES: SERASA EXPERIAN · ABECS MONITOR DE FRAUDES · FEBRABAN · POLÍCIA FEDERAL · 2024-2025

A CADEIA DO CRIME · ONDE O MODELO ENTRA

A transação é o *meio*, não o fim



*O modelo age em um único elo da cadeia. **Bloquear a transação interrompe tudo que vem depois** — mas o alerta também alimenta a investigação de quem está atrás dela.*

ALÉM DO MODELO · O QUE A CYBER PRECISA CONSIDERAR

Detecção não é só *acertar a fraude*

CASH-OUT · CONTA LARANJA

A ponta visível do esquema

Quem cede a conta para o trânsito de recursos ilícitos virou crime tipificado (**Lei 15.397/2026**), com pena de 1 a 5 anos. Detectar o laranja é atacar o crime onde ele se materializa.

PLD / AML · KYC

Prevenção à lavagem de dinheiro

Bancos precisam **conhecer o cliente (KYC)**, monitorar operações atípicas e reportar. Falhar não é só perder dinheiro: gera multa e sanção do Banco Central.

LGPD · DIREITO DO TITULAR

A decisão precisa ser explicável

Recusar uma compra é uma decisão automatizada. Pela **LGPD**, o titular pode pedir revisão e explicação — o que empurra a escolha do modelo para o lado da interpretabilidade.

ADVERSÁRIO

Fraude é crime organizado

Não é um ator isolado: é uma operação que aprende, muda de tática em semanas e financia outros crimes. O alerta é **insumo de investigação**, não só um bloqueio.

ATIVIDADE · DESENHAR A ESTRATÉGIA, SEM CÓDIGO

Vocês são o time de dados de uma *operadora*

100 mil transações por dia · 170 fraudes · 200 ms para decidir · 400 alertas/dia de capacidade · rótulo chega 20 dias depois.

1

A DECISÃO

O que o modelo decide, quando, e que ação dispara.

2

FEATURES

Oito ou mais, em quatro famílias, cada uma com o sinal que captura.

3

ALGORITMO

Escolha e justificativa pelas restrições.

4

A RARIDADE

Como o treino lida com 578:1 e o efeito colateral.

5

AValiação e Operação

Contagens, limiar, capacidade do time.

6

RISCOS E LIMITES

Drift, adversário, vazamento, viés, LGPD.

PRÓXIMA AULA · A DEMONSTRAÇÃO

O que os números vão *testar*

- ◆ Dataset real de fraude de cartão (ULB, 284.807 transações, 492 fraudes), com features anonimizadas por PCA.
 - ◆ Regressão logística e Random Forest contra **undersampling**, **oversampling**, **SMOTE** e **pesos de classe**.
 - ◆ Três armadilhas que aparecem em relatórios de verdade, inclusive em livros.
 - ◆ Cada dupla verifica **quais hipóteses do seu canvas sobrevivem aos números**.
-

Leituras: Chio e Freeman, cap. 5, seção "Class imbalance" (principal) · Halder e Ozdemir, cap. 10 · Chawla et al., SMOTE, JAIR 2002.