

INSPER · AULA 08 · CIBERSEGURANÇA · CIÊNCIA DA COMPUTAÇÃO

Meu modelo é *bom*?

Como avaliar modelos de ML em segurança

PARTE 1 Demonstração da Aula 7: o que cada técnica de balanceamento faz com as contagens

PARTE 2 Dar nome às contagens: matriz de confusão, precisão, recall, F1, treino versus teste, curvas ROC e PR

PROFESSOR

João Luisi

TEMA

Avaliação de modelos

```
~$ python avaliar.py --model rf
acurácia: 0.9996
precisão: 0.941 · recall: 0.816
f1: 0.874
# a acurácia esconde tudo
confusion_matrix(y_test, y_pred)
[[56859   5]
 [   18 80]]
```



PARTE 1 · A DEMONSTRAÇÃO · MODELO BASE

Por que a fronteira *se acomoda*

REGRESSÃO LOGÍSTICA, SEM TRATAMENTO

62 / 98

fraudes detectadas

13

alarmes falsos

36 (37%)

fraudes perdidas

O MECANISMO

O otimizador vai para onde dói menos

O otimizador minimiza o **erro total**. Errar uma fraude custa o mesmo que errar uma legítima, e há **578 legítimas para cada fraude**.

A fronteira se acomoda do lado que dói menos: o da maioria.

TÉCNICA 1 · UNDERSAMPLING ALEATÓRIO

Jogar fora a *maioria*

Descartar transações legítimas do treino, ao acaso, até que as classes fiquem **1:1**. O conjunto de teste não é tocado.

788

linhas de treino (de 227.845)

90 / 98

fraudes detectadas

1.655

alarmes falsos (eram 13)

O QUE GANHOU

Treino instantâneo. A fronteira se deslocou para o lado das legítimas e passou a capturar **quase todas as fraudes**.

O QUE PERDEU

99,8% do conhecimento sobre o que é "normal". Tudo que foge um pouco do padrão dos 394 legítimos restantes vira suspeito.

TÉCNICAS 2 E 3 · OVERSAMPLING E SMOTE


Duplicar ou *inventar* fraudes

OVERSAMPLING ALEATÓRIO · 90/98 · 1.383 ALARMES

Copia fraudes existentes até 1:1. **Nenhuma informação nova.**

SMOTE · CHAWLA ET AL., 2002 · 90/98 · 1.453 ALARMES

Para cada fraude, escolhe um dos 5 vizinhos mais próximos e **cria um ponto no segmento entre os dois.**



PONTOS LARANJA: FRAUDES SINTÉTICAS INTERPOLADAS ENTRE FRAUDES REAIS

- ◆ Onde fraudes reais estão isoladas, o SMOTE **atravessa regiões vazias** e ensina fraude onde nunca houve.
- ◆ Vizinhos por distância euclidiana: **escalar antes**, ou **Time** domina tudo. Supõe features contínuas.

TÉCNICA 4 · PONDERAÇÃO DE CLASSES

Sem reamostrar: *mudar o custo*

Em vez de mexer nos dados, dizer ao modelo que errar uma fraude custa mais: `class_weight="balanced"` multiplica o peso de cada fraude por 578 na função de custo.

ESTRATÉGIA	LINHAS DE TREINO	DETECTADAS	ALARMES FALSOS	TEMPO
Oversampling aleatório	454.902	90 / 98	1.383	2,9 s
<code>class_weight="balanced"</code>	227.845	90 / 98	1.386	0,7 s

- ◆ Duplicar cada fraude 578 vezes ou multiplicar seu peso por 578 é, para a regressão logística, **a mesma conta**.
- ◆ Sem 454 mil linhas na memória, sem dados sintéticos, sem risco de vazamento. Em muitos cenários reais é a **primeira coisa a tentar**, e às vezes a última.
- ◆ Modelos de árvore (Random Forest, XGBoost) também aceitam pesos de classe.

CINCO ESTRATÉGIAS, UM MESMO CONJUNTO DE TESTE

O mesmo *trade-off*, de quatro jeitos

ESTRATÉGIA	DETECTADAS	ALARMES POR FRAUDE
Base (sem tratamento)	62 / 98	0,2
Undersampling	90 / 98	18,4
Oversampling	90 / 98	15,4
SMOTE	90 / 98	16,1
class_weight	90 / 98	15,4

Quatro técnicas, um mesmo trade-off: 90 detectadas ao custo de 1.400 a 1.700 alarmes. Qual venceu? Depende do custo de cada erro, que o dataset não contém.

ARMADILHA 1 · SMOTE ANTES DO SPLIT

Quando o resultado é *bom demais*

Reamostrar o dataset inteiro e só depois dividir em treino e teste.

55.171

"fraudes" detectadas no teste

97%

de recall aparente

- ◆ O teste tem 56.863 "fraudes": quase todas sintéticas, interpoladas a partir de fraudes que **também estão no treino**.
- ◆ O modelo é avaliado em pontos que ficam no meio do caminho entre exemplos que ele já viu: **vazamento**. O teste deixou de representar o mundo (0,17% de fraude, todas genuínas).

REGRA

Reamostragem **só no treino, sempre depois do split**. O Pipeline do imbalanced-learn faz isso sozinho.

ARMADILHAS 2 E 3 · QUANDO O NÚMERO ENGANA

Teste na *proporção errada*

Undersampling do dataset inteiro (492×492) e avaliação nesse conjunto.

93 / 98

fraudes detectadas

2

alarmes falsos em 99 legítimas

≈ 1.150

seriam os alarmes em 56.864 legítimas

- ♦ **Armadilha 2:** parece o melhor modelo do dia — é o undersampling do item d), maquiado. Os alarmes "sumiram" porque só havia 99 legítimas para errar. Na proporção real, seriam mais de mil. **Regra: o teste tem de ter a proporção real das classes.**
- ♦ **Armadilha 3, sutil:** SMOTE sem escalar. Os vizinhos passam a ser definidos por **Time** e o resultado (88 detectadas, 568 alarmes) vem de outro algoritmo.

O QUE LEVAR DA DEMONSTRAÇÃO

Cinco lições da *Parte 1*

1 **Acurácia não é métrica para classes raras**
Sempre reportar fraudes detectadas e alarmes falsos. Os nomes formais chegam na Parte 2.

2 **Reamostragem só no treino, depois do split**
E o teste com a proporção real. Use o Pipeline do imbalanced-learn.

3 **Balancear é mover a fronteira**
Undersampling, oversampling, SMOTE e pesos são quatro jeitos de fazer a mesma coisa. Nem sempre ajudam. O limiar é a alavanca mais barata.

4 **Não há vencedor sem custos**
Qual erro dói mais? A resposta vem do negócio, não do dataset. Roteiro 3.

5 **Fraude se move**
Um modelo de 2013 não detecta a fraude de 2026. Monitoramento e retreino: Aula 20.

PARTE 2

Dar nome às *contagens*

Fraudes detectadas, fraudes perdidas e alarmes falsos têm nomes formais desde 1950. Hoje vocês calculam à mão, depois o notebook confirma.



EXERCÍCIO RELÂMPAGO · CALCULE À MÃO

As contagens de seis *modelos*

MODELO	TP	FN	FP	TN
Nulo	0	98	0	56.864
LR base	62	36	13	56.851
LR + undersampling	90	8	1.655	55.209
LR + SMOTE	90	8	1.453	55.411
LR + class_weight	90	8	1.386	55.478
RF base	80	18	5	56.859

PARA CADA LINHA

$$P = TP / (TP + FP)$$

$$R = TP / (TP + FN)$$

$$F1 = 2 \cdot P \cdot R / (P + R)$$

$$Acc = (TP + TN) / 56.962$$

Depois: ordene os seis modelos por F1 e por recall.

10 minutos, em dupla, sem computador. A pergunta que importa: os dois rankings coincidem?

A MATRIZ DE CONFUSÃO, COM NOMES

Quatro quadrantes, *duas perguntas*

	PREVISTO: FRAUDE	PREVISTO: LEGÍTIMA
REAL: FRAUDE	Verdadeiro positivo TP · FRAUDE DETECTADA	Falso negativo FN · FRAUDE PERDIDA
REAL: LEGÍTIMA	Falso positivo FP · ALARME FALSO	Verdadeiro negativo TN · LEGÍTIMA APROVADA

- ◆ **Recall:** $TP / (TP + FN)$. A linha de cima. "Das fraudes, quantas pegamos?"
- ◆ **Precisão:** $TP / (TP + FP)$. A coluna da esquerda. "Dos alertas, quantos valeram?"
- ◆ **F1:** média harmônica das duas. Pune quem sacrifica uma delas.
- ◆ **Acurácia:** as duas diagonais azuis sobre o total. Dominada pelo TN.

REVELAÇÃO · DOIS RANKINGS QUE NÃO COINCIDEM

A métrica *decide* o vencedor

MODELO	ACURÁCIA	PRECISÃO	RECALL	F1
RF base	99,96%	0,941	0,816	0,874
LR base	99,91%	0,827	0,633	0,717
LR + class_weight	97,55%	0,061	0,918	0,114
LR + SMOTE	97,43%	0,058	0,918	0,110
LR + undersampling	97,08%	0,052	0,918	0,098
Nulo	99,83%	0,000	0,000	0,000

ACURÁCIA

Entre 97% e 99,96% para todos. Não separa o nulo do melhor. **Descartada.**

RECALL × F1

As balanceadas lideram em recall (0,92) e afundam em F1 (0,10): precisão de 5%. O F1 pune o desequilíbrio.

MAS F1 ASSUME PESOS IGUAIS

Fraude perdida e alarme falso não custam o mesmo. Roteiro 3.

TREINO, VALIDAÇÃO E TESTE

Três conjuntos, *um só medidor honesto*

TREINO

Aprender

O modelo ajusta seus parâmetros aos dados



VALIDAÇÃO

Escolher

Profundidade, número de árvores, limiar



TESTE

Medir uma vez

Uma única medição, no fim de tudo

- ◆ Métrica de treino mede o que o modelo **decorou**, não o que aprendeu.
- ◆ Toda escolha feita olhando o teste transforma o teste em validação; **sobra nada para medir**.
- ◆ Com dados que têm tempo (logs, transações), a divisão honesta é **temporal**: treinar no passado, validar e testar no futuro. Validação cruzada é a alternativa quando os dados são poucos; em dados temporais, só a versão que respeita a ordem.

OVERFITTING COMO NÚMERO

A distância entre *treino e teste*

MODELO	CONJUNTO	PRECISÃO	RECALL	F1
LR base	treino	0,883	0,629	0,735
	teste	0,827	0,633	0,717
RF base	treino	1,000	0,995	0,997
	teste	0,941	0,816	0,874

RANDOM FOREST


Recall 0,995 no treino: **decorou as 394 fraudes**. A queda para 0,816 no teste é o overfitting, medido.

REGRESSÃO LOGÍSTICA

Treino e teste quase iguais: 30 coeficientes não têm capacidade para decorar. Ruim nos dois seria **underfitting**.

CURVAS ROC E PRECISION-RECALL

Uma curva por *limiar*



CADA PONTO É UM LIMIAR SOBRE PREDICT_PROBA - A LINHA PONTILHADA DA PR É O ACASO (0,17%)

ROC

Recall contra taxa de falsos positivos. 1.400 alarmes em 56.864 legítimas são 2,5%: **a ROC não vê.**

PRECISION-RECALL

Precisão contra recall. Aqui os modelos **se separam**.

Onde operar na curva e quanto vale a área sob ela: pergunta do **Roteiro 3**.

O QUE LEVAR · E O EXERCÍCIO ASSÍNCRONO

Quatro ideias para *levar*

- ◆ Acurácia está descartada para classes raras. **Recall e precisão** são as duas contagens da Aula 8 com nome.
- ◆ F1 pune o desequilíbrio, mas assume que os dois erros **custam o mesmo**.
- ◆ Métrica de treino não é desempenho. Escolhas exigem validação, **temporal quando há tempo**.
- ◆ ROC é cega ao desbalanceamento; a **curva PR não**. Onde operar nela: Roteiro 3.

EXERCÍCIO ASSÍNCRONO · MEIA PÁGINA POR DUPLA, SEM NOTA

Precisão, recall, F1 e matriz de confusão do **Random Forest do Roteiro 2 (CICIDS2017)**, no teste do split temporal. Uma frase: qual métrica você reportaria ao SOC e por quê. Leitura: **Géron, cap. 3**.